

ETL BIBLIOTECA

Estudiante: Gaspar Andres Garcia Quiroz

Grupo: 9A

Materia: Extracción de conocimiento de Bases de Datos

Fecha: 05/07/2026

Base de Datos: biblioteca_dw

1. INFORMACIÓN GENERAL DEL PROYECTO

Este documento detalla el proceso de Extracción, Transformación y Carga (ETL) para el sistema de biblioteca, asegurando la integridad de los datos y la generación de un almacén de datos (Data Warehouse) funcional.

2. ESTRUCTURA DEL REPOSITORIO



unidad2_etl_biblioteca

Public

 Pin

 Watch 0

main

1 Branch

0 Tags

Go to file

T

Add file

<> Code

Ander-tsx

examen

05ee69f · now

2 Commits

data	examen	now
evidencias	examen	now
scripts	examen	now
sql	examen	now
.env.example	examen	now
.gitignore	Initial commit	2 hours ago
README.md	examen	now


3. EJECUCIÓN DEL SCRIPT ETL

```
~/DEV/UTEZ/9A/unidad2_etl_biblioteca git:(main) 0 • +0 -0 (0.055s)
clear

~/DEV/UTEZ/9A/unidad2_etl_biblioteca git:(main) 0 • +0 -0 (0.75s)
python3 scripts/etl_biblioteca.py
[INFO] Leyendo archivo: /Users/ander/DEV/UTEZ/9A/unidad2_etl_biblioteca/data/prestamos_biblioteca_100.csv
[INFO] Filas leídas del CSV: 100
[INFO] Registros válidos : 98
[INFO] Registros con error: 2
[INFO] Conectando a MySQL localhost:3307 / biblioteca_dw ...
[INFO] Tablas verificadas / creadas correctamente.
[INFO] Tablas truncadas (excepto etl_log).
[INFO] Dimensiones cargadas.
[INFO] fact_prestamos cargada: 98 registros.
[INFO] etl_errores cargada: 2 registros.
[INFO] etl_log actualizado.
[INFO] Transacción confirmada (COMMIT).
[INFO] Reporte generado: /Users/ander/DEV/UTEZ/9A/unidad2_etl_biblioteca/evidencias/reporte_ejecucion.txt


=====
RESUMEN DE EJECUCIÓN ETL
=====
Filas leídas      : 100
Filas cargadas   : 98
Filas rechazadas : 2
Estado           : FINALIZADO_CON_ERRORES
=====
```

4. TABLAS CREADAS EN MYSQL



The screenshot shows a MySQL IDE interface. The top panel displays the command `SHOW TABLES;` with line numbers 117, 118, 119, and 120. The bottom panel shows the 'Services' section with a tree view of the database structure. The 'biblioteca_dw' database is selected, and the 'Tables_in_biblioteca_dw' table is expanded, showing a list of tables: `dim_alumno`, `dim_carrera`, `dim_fecha`, `dim_libro`, `dim_sede`, `etl_errores`, `etl_log`, and `fact_prestamos`.


5. TABLA fact_prestamos (Primeros 20 registros)



The screenshot shows a MySQL IDE interface. The top panel displays the command `SELECT * FROM fact_prestamos LIMIT 20;` with line numbers 132, 133, 134, and 135. The bottom panel shows the 'Services' section with a table view of the first 20 records of the `fact_prestamos` table. The table has columns: `id_prestamo`, `id_fecha`, `id_alumno`, `id_carrera`, `id_libro`, `id_sede`, `dias_prestamo`, and `mu`.

id_prestamo	id_fecha	id_alumno	id_carrera	id_libro	id_sede	dias_prestamo	mu
1	5001	1	2	2	8	1	3
2	5002	2	10	4	2	3	5
3	5003	3	19	3	7	4	7
4	5004	4	16	5	9	2	2
5	5005	5	9	1	5	1	4
6	5006	6	3	2	3	3	6
7	5007	7	11	4	6	4	8
8	5008	8	8	3	10	2	1
9	5009	9	4	5	1	1	9
10	5010	10	15	1	4	3	10
11	5011	11	18	2	8	4	3

6. TABLA etl_errores — REGISTROS RECHAZADOS



The screenshot shows a MySQL IDE interface. The top panel displays the command `SELECT * FROM etl_errores;` with line numbers 143, 144, 145, and 146. The bottom panel shows the 'Services' section with a table view of the `etl_errores` table. The table has columns: `id_error`, `fecha_error`, `archivo_origen`, `fila_csv`, `id_registro`, and `descripcion_error`.

id_error	fecha_error	archivo_origen	fila_csv	id_registro	descripcion_error
1	2026-07-05 18:20:19	data/prestamos_biblioteca_100.csv	101	5002	id_prestamo duplicado; se conser
2	2026-07-05 18:20:19	data/prestamos_biblioteca_100.csv	100	5099	total_multa incorrecto: valor=40

7. TABLA etl_log — HISTORIAL DE EJECUCIONES

The screenshot shows a database client interface with a sidebar on the left containing a tree view of the database structure. The main area displays the 'etl_log' table from the 'biblioteca_dw' database. The table has six columns: 'id_log', 'fecha_ejecucion', 'archivo_origen', 'filas_leidas', 'filas_cargadas', and 'filas_rechazadas'. The data is presented in a table format with four rows. The interface includes a top bar with a query editor showing 'SELECT * FROM etl_log;', a 'Services' section, and a 'Database' section with a 'console' tab.

id_log	fecha_ejecucion	archivo_origen	filas_leidas	filas_cargadas	filas_rechazadas
1	2026-07-05 13:47:49	prestamos_biblioteca_100.csv	100	98	
2	2026-07-05 17:47:51	data/prestamos_biblioteca_100.csv	100	98	
3	2026-07-05 17:48:10	data/prestamos_biblioteca_100.csv	100	98	
4	2026-07-05 18:20:19	data/prestamos_biblioteca_100.csv	100	98	

8. CONSULTAS SQL DE VERIFICACIÓN

```
console [mysql-data-analysis] x

167 -- 1. ¿Cuántos registros hay en fact_prestamos?
168 SELECT COUNT(*) AS total_registros_fact_prestamos
169 FROM fact_prestamos;
170
171 -- =====
172
173 -- 2. ¿Cuántos registros hay en etl_errores?
174 SELECT COUNT(*) AS total_errores
175 FROM etl_errores;
176
177 -- =====
178
179 -- 3. ¿Qué errores fueron registrados?
180 SELECT
181     id_error,
182     fecha_error,
183     fila_csv,
184     id_registro AS id_prestamo,
185     descripcion_error
186 FROM etl_errores
187 ORDER BY id_error;
188
189 -- =====
190
191 -- 4. ¿Cuál fue el último estado registrado en etl_log?
192 SELECT
193     id_log,
194     fecha_ejecucion,
195     archivo_origen,
196     filas_leidas
197 FROM etl_log
198 ORDER BY fecha_ejecucion DESC
199 LIMIT 1;
```

mysql-data-analysis] 286:1 LF etc...

9. EXPLICACIÓN DEL FLUJO ETL

EXTRACT

- **Fuente:** Lectura de archivos CSV mediante la librería `pandas`.
- **Procesamiento Inicial:** Estandarización de nombres de columnas, limpieza de caracteres especiales en texto y conversión de tipos de datos (dates, integers).
- **Control de Calidad:** Verificación preliminar de valores nulos y respaldo de la fila original para trazabilidad.

TRANSFORM

- **Gestión de Duplicados:** Implementación de lógica de deduplicación basada en la llave primaria del negocio (`id_prestamo`).
- **Validación de Negocio:** Cálculo dinámico de multas para validar la integridad financiera del registro (`dias_prestamo * multa_diaria`).
- **Mapeo Dimensional:** Construcción y búsqueda de IDs en las tablas de dimensiones para asegurar la coherencia en el esquema estrella.

LOAD

- **Infraestructura:** Conexión segura a MySQL.
- **Idempotencia:** Truncado preventivo de tablas operativas (excepto logs) para permitir re-ejecuciones limpias.
- **Persistencia:** Inserción secuencial de dimensiones, seguido de `fact_prestamos` y el registro de excepciones en `etl_errores`.
- **Cierre:** Actualización automática del log de auditoría y generación del reporte final de ejecución.